

Data Table - Orange

Info
13 instances (no missing data)
140 features (sparse, density 100.00 %)
No target variable.
1 meta attribute

Variables
☒ Show variable labels (if present)
☐ Visualize numeric values
☒ Color by instance classes

Selection
Clear Selection
☒ Select full rows

Restore Original Order
☒ Send Automatically

	bow-feature	hidden	include	skip-normalization	title
1	적용대상: 철강 ...	1차=1, 2차=1, 72류=1, 76류=1, 가공품...	True	True	{...}
2	의무사항: 수입...	1개월=1, cbam=1, 등록시스템에=1, 배...			
3	의무사항: 확정...	1=2, 2026=1, 31일까지=1, 5월=1, cba...			
4	벌칙조항: 미신...	10=1, 50유로=1, 가중=1, 과징금=1, 미...			
5	적용대상: 시멘...	25류=1, 31류=1, 등=1, 밋=1, 비료=1, ...			
6	의무사항: 시멘...	공정배출을=1, 구분=1, 산정=1, 시멘트...			
7	벌칙조항: 과거 ...	경우=1, 과거=1, 배출계수를=1, 벌칙조...			
8	적용대상: 수소(...	00=1, 10=1, 2716=1, 2804=1, cn=2, ...			
9	의무사항: 전력...	개별=1, 발전소가=1, 배출계수를=1, 수...			
10	의무사항: 수소...	그레이=1, 그린=1, 다르므로=1, 따라=...			
11	공통원칙: 내재...	간접배출을=1, 개념으로=1, 공통=1, 공...			
12	공통원칙: 실측...	eu=1, 검증기관의=1, 검증보고서를=1, ...			
13	공통원칙: 배출...	4년간=1, 검증=1, 공통원칙=1, 근거=1,...			

13 | 13 | 13

CSV 3종 컬럼 구조 준비risk_keywords.csv는 키워드(word)와 가중치(weight) 두 컬럼, sample_docs.csv는 문서ID와 본문 텍스트(text) 컬럼, risk_threshold.csv는 등급(level: 빨강/노랑/초록)과 점수 구간(min/max) 컬럼으로 구성합니다. 세 파일 모두 헤더 행이 있어야 File 위젯이 컬럼 타입(문자열/숫자)을 자동 인식합니다.


File 위젯 3개 배치 및 연결캔버스에 File 위젯을 3개 놓고 각각 risk_keywords.csv, sample_docs.csv, risk_threshold.csv를 지정합니다. sample_docs를 연결한 File 위젯 뒤에는 반드시 Corpus 위젯을 하나 더 연결해야 합니다 — 일반 File 위젯 출력은 '표(Table)' 형식이라 텍스트 전용 위젯들이 바로 입력받지 못하기 때문입니다.



텍스트 정제 (Preprocess Text)Corpus 위젯 출력을 Preprocess Text 위젯에 연결합니다. 위젯 내에서 소문자 변환(Lowercase), 토큰화(Tokenize), 불용어 제거(Stopwords) 단계를 순서대로 거쳐 sample_docs의 원문을 정제된 토큰 집합으로 만듭니다.

단어 빈도 집계 (Bag of Words)정제된 Corpus를 Bag of Words 위젯에 연결하면 문서별 단어 등장 횟수가 표(Table) 형식으로 출력됩니다. 이 표를 Data Table 위젯에 연결해 실제로 risk_keywords에 있는 단어들이 컬럼으로 잡혔는지 눈으로 확인하는 것이 좋습니다.

risk_keywords.csv 가중치 값 먼저 확인risk_keywords.csv를 연결한 File 위젯에 Data Table 위젯을 하나 더 연결해서 여세요. word 컬럼과 weight 컬럼이 나란히 보일 겁니다. 여기 적힌 단어-가중치 쌍을 메모장이나 종이에 옮겨 적어두세요. 예: 배출=2, 인증서=3, 벌칙=2, 과징금=3 식으로. 이 값들을 이후 Feature Constructor 수식에 그대로 타 이핑할 거라 미리 확보해두는 게 편합니다.

Bag of Words 출력에 Select Columns 연결5번 단계에서 만든 Bag of Words 위젯 출력을 (Data Table 말고) Select Columns 위젯에 새로 연결하세요. Select Columns를 더블클릭해 열면 왼쪽에 'Available Variables'로 140개 단어 컬럼이 전부 나열됩니다.





Features 전체 선택오른쪽 'Features (140)' 목록 안의 단어 하나(예: '00')를 클릭한 다음, 키보드 Ctrl+A(맥은 Cmd+A)를 누릅니다. 140개 단어가 모두 파랑색으로 선택됩니다.

2) 전부 Ignored로 이동선택된 단어 아무거나를 마우스로 누른 채 왼쪽 'Ignored' 칸으로 끌고 가서 놓습니다(드래그 앤 드롭). 놓으면 Ignored에 140개, Features에 0개가 됩니다. 이제부터가 진짜 시작입니다.

3) Ignored에서 키워드 검색원쪽 'Ignored' 칸 위의 Filter 칸에 맨 첫 번째 키워드(예: '과징금')를 입력합니다. 목록이 해당 단어만으로 줄어듭니다.

4) 화살표로 Features에 추가필터된 단어를 클릭한 다음, 가운데 첫 번째 '>' 화살표를 누릅니다. 해당 단어가 오른쪽 Features로 다시 이동합니다.

5) 나머지 29개 반복정리해둔 30개 키워드(가지치신 리스트) 또는 그에 대응하는 실제 토큰명('허위신고로' 같은 변형포함)을 하나씩 검색하면서 3~4번을 반복합니다. 안 나오는 단어는 넘어갑니다.

6) 개수 마무리 확인화면 상단 'Features (숫자)'가 마지막에 옥겨진 단어 개수와 같은지 확인합니다. 맞으면 창을 닫고 Feature Constructor 연결(다음 단계)으로 넘어가세요.

지금 Select Columns에서 하시는 일은 한 문장으로 말하면 **140개 단어 컬럼 중에서, 내가 만든 리스크 키워드 사전에 있는 단어들만 골라내는 필터링 작업**입니다.

왜 이 작업이 필요한지 전체 흐름 속에서 설명드리면:

1. **Bag of Words**가 13개 문서에 등장하는 모든 단어를 세어서 **140개 컬럼**을 만들었습니다. 여기엔 "과징금"처럼 리스크와 직결된 단어도 있지만, "00", "1", "2026", "cbam" 처럼 리스크 판단과 무관한 단어도 잔뜩 섞여 있습니다.
2. 다음 단계(Feature Constructor)에서 만들 **risk_score**(가중합 점수)는 "선택된 단어들의 등장 횟수 × 가중치"를 더하는 수식입니다. 만약 140개를 다 넣고 계산하면 리스크와 무관한 단어까지 점수에 섞여서 결과가 엉망이 됩니다.
3. 그래서 **Select Columns**가 하는 역할은 "계산에 쓸 재료만 추려내는 체"입니다 — 140개 중 리스크 키워드에 해당하는 것만 오른쪽(Features)에 남기고, 나머지는 왼쪽(Ignored)으로 보내 아예 다음 단계로 넘어가지 못하게 막는 겁니다.

4. 지금까지 8개를 골라내셨고, 이 작업이 다 끝나면 Features 칸에는 **"리스크와 직접 관련된 단어들만"** 남게 되고, 이게 그대로 Formula로 넘어가서 수식의 재료가 됩니다.


즉, 지금 하시는 건 계산이 아니라 *****계산에 쓸 변수(재료)를 고르는 준비 작업*****이라고 보시면 됩니다

Feature Constructor 연결Select Columns에서 옴김 30개 단어가 확정되면, 그 창을 닫으세요 (자동 저장됨). Select Columns 위젯 출력을 새로 Formula 위젯에 연결하고 더블클릭해 엽니다.

새 변수 이름 설정상단 'New feature name' 칸에 risk_score를 입력합니다. 그 아래 'Expression' 칸에 수식을 쓸 거랍니다. 화면 오른쪽 'Variables' 목록에서 단어를 더블클릭하면 철자 오류 없이 수식창에 자동 입력되는데, 단어가 30개라 이 방식을 강력히 추천드립니다.

가중합 수식 작성수식은 각 단어에 가중치를 곱해서 다 더하는 형태입니다. 지금까지 옥겨진 8개로 예를 들면: (과징금 * 5) + (허위신고로 * 4) + (미신고 * 4) + (위반 * 4) + (검증 * 3) + (요청에 * 가중치) + (인증서를 * 가중치) + (실측값 * 가중치) 식으로, 나머지 단어들도 같은 패턴으로 계속 이어붙입니다. 이미 생성된 토큰은 백틱(`)이 자동 붙으며, 괄호로 각 항목을 감싸주면 가독성이 좋습니다.

결과 확인 Formula 창 하단의 적용 버튼(또는 창을 닫으면 자동 적용)을 누른 다음, Feature Constructor 출력을 Data Table에 새로 연결해 열어보세요. 기존 컬럼들 오른쪽 끝에 risk_score라는 숫자 컬럼이 생겨서, 문서(행)별로 점수가 계산되어 있으면 성공입니다.



Data Table (2) - Orange

Info
13 instances (no missing data)
8 features (tags, density 100.00 %)
No target variable.
2 meta attributes

Variables
☒ Show variable labels (if present)
☐ Visualize numeric values
☒ Color by instance classes

Selection
Clear Selection
☒ Select full rows

Restore Original Order
☒ Send Automatically

	텍스트	risk_score	
bow-feature			
hidden			
include	True		{...}
skip-normalization	True		
title			
1	적용대상: 철강...	?	
2	의무사항: 수입...	?	
3	의무사항: 확정...	4.0	인증서를
4	벌칙조항: 미신...	13.0	과징금, 미신고,...
5	적용대상: 시멘...	?	
6	의무사항: 시멘...	?	
7	벌칙조항: 과거 ...	4.0	허위신고로
8	적용대상: 수소(...	?	
9	의무사항: 전력...	?	
10	의무사항: 수소...	?	
11	공통원칙: 내재...	?	
12	공통원칙: 실측...	2.0	실측값
13	공통원칙: 배출...	5.0	검증, 요청에

13 | 13

1) risk_threshold.csv 기준값 확인
risk_threshold.csv를 연결한 File 위젯에 Data Table을 하나 연결해 열어보세요. 등급(빨강/노랑/초록)과 점수 구간(min/max 또는 기준값)이 몇 점인지 숫자로 메모해둡니다.

Data Table (3) - Orange

Info
3 instances (no missing data)
2 features
No target variable.
1 meta attribute

Variables
☒ Show variable labels (if present)
☐ Visualize numeric values
☒ Color by instance classes

Selection
Clear Selection
☒ Select full rows

Restore Original Order
☒ Send Automatically

	등급	하한	상한
1	초록	0	5
2	노랑	6	15
3	빨강	16	999

Formula - Orange

Variable Definitions

New 증서를) * 4) + ((0 if 실측값 != 실측값 else 실측값) * 2)

Remove ☐ Meta attribute Select Feature Select Function

N risk_score := ((0 if 과징금 != 과징금 else 과징금) * 5) + ((0 if 허위신고로 != 허위신고로 else 허위신고

Send

Formula (1) - Orange

Variable Definitions

New

risk_level

f risk_score >= 5 else ('노랑' if risk_score >= 2 else '초록')

Remove

☒ Meta attribute

Select Feature

Select Function

S

risk_level := '빨강' if risk_score >= 5 else ('노랑' if risk_score >= 2 else '초록')

Send

?

13

13

```

graph LR
    File1[File (1)] -- Data --> DT1[Data Table (1)]
    File2[File (2)] -- Data --> DT3[Data Table (3)]
    Corpus[Corpus] -- Corpus --> Preprocess[Preprocess Text]
    Preprocess -- Corpus --> BoW[Bag of Words]
    BoW -- "Corpus -> Data" --> DT[Data Table]
    BoW -- "Corpus -> Data" --> SC[Select Columns]
    SC -- Data --> F1[Formula]
    F1 -- Data --> F2[Formula (1)]
    F2 -- Data --> DT2[Data Table (2)]
  
```

The diagram illustrates a data processing workflow in Orange Data Mining. It starts with two file inputs, File (1) and File (2), which feed into Data Table (1) and Data Table (3) respectively via 'Data' connections. A main workflow begins with a 'Corpus' widget, which connects to 'Preprocess Text' and then to 'Bag of Words' via 'Corpus' connections. From 'Bag of Words', there are two paths: one labeled 'Corpus -> Data' leading to a 'Data Table' widget, and another labeled 'Corpus -> Data' leading to a 'Select Columns' widget. The 'Select Columns' widget feeds into a 'Formula' widget, which then feeds into 'Formula (1)', and finally into 'Data Table (2)', all connected by 'Data' links.

Data Table (2) - Orange					
Info 13 instances (no missing data) 8 features (tags, density 100.00 %) No target variable. 3 meta attributes Variables ☒ Show variable labels (if present) ☐ Visualize numeric values ☒ Color by instance classes Selection Clear Selection ☒ Select full rows Restore Original Order ☒ Send Automatically ? 13 13 13					
bow-feature hidden include skip-normalization title	텍스트	risk_score	risk_level	{...}	
	True				
1	적용대상: 절강 ...	?	초록		
2	의무사항: 수입...	?	초록		
3	의무사항: 확정...	4.0	노랑	인증서를	
4	벌칙조항: 미신...	13.0	빨강	과징금, 미신고...	
5	적용대상: 시면...	?	초록		
6	의무사항: 시면...	?	초록		
7	벌칙조항: 과거 ...	4.0	노랑	허위신고로	
8	적용대상: 수소(...	?	초록		
9	의무사항: 전력...	?	초록		
10	의무사항: 수소...	?	초록		
11	공통원칙: 내재...	?	초록		
12	공통원칙: 실측...	2.0	노랑	실측값	
13	공통원칙: 배출...	5.0	빨강	검증, 요청에	